Ciência de Dados Aplicada à Gestão de Riscos: Modelagem Preditiva de Volatilidade para Suporte à Decisão no Índice Bovespa

Lorrana E. A. Pereira, Arlino H. M. Araújo

Curso Superior de Tecnologia em Gestão de Dados - Universidade Federal do Piauí(UFPI) - Centro de Educação Aberta e à distância (CEAD) - Polo de Teresina 64049-550 - Teresina - PI - Brasil

{lorrana.pereira@ufpi.edu.br}{arlino@ufpi.edu.br}

Abstract. *The financial market requires robust analytical strategies for risk management and decision-making. However, predicting asset behavior is a complex challenge due to its high volatility. To solve this problem, this study proposes the application of Machine Learning techniques (XGBoost, LightGBM, and Neural Networks) in the predictive volatility modeling of the Bovespa Index (2016-2026), creating an efficient and interpretable decision-support system using the SHAP and LIME methods. The results demonstrate that Gradient Boosting models outperformed neural networks, proving the effectiveness of these technologies in anticipating market fluctuations and assisting in capital protection.*

Keywords. *Machine Learning, Data Science, Financial Risk Forecasting, Market Volatility*

Resumo. O mercado financeiro exige estratégias analíticas robustas para a gestão de risco e tomada de decisão. Contudo, prever o comportamento dos ativos é um desafio complexo devido à sua elevada volatilidade. Para solucionar este problema, este estudo propõe a aplicação de técnicas de Aprendizagem de Máquina (*XGBoost, LightGBM* e Redes Neurais) na modelação preditiva da volatilidade do Índice Bovespa (2016-2026), criando um sistema de suporte à decisão eficiente e interpretável através dos métodos *SHAP* e *LIME*. Os resultados demonstram que os modelos de *Gradient Boosting* superaram as redes neurais, comprovando a eficácia destas tecnologias para antecipar flutuações no mercado e auxiliar na proteção do capital.

Palavras-chave. Aprendizado de Máquina, Ciência de Dados, Previsão de Riscos Financeiros, Volatilidade de Mercado.

1. Introdução

O mercado financeiro desempenha um papel fundamental na economia ao atuar como intermediador entre agentes que possuem recursos disponíveis para investimento e aqueles que necessitam de capital (ASSAF NETO, 2021). Por meio de seus diversos instrumentos e modalidades de aplicação, oferece oportunidades para a valorização do patrimônio, possibilitando rentabilidades que podem superar a inflação e contribuir para a preservação do poder de compra ao longo do tempo. Além disso, amplia as possibilidades de geração de renda para indivíduos e empresas por meio de estratégias de investimento alinhadas aos seus objetivos e perfis.

Entretanto, as operações realizadas nesse ambiente estão sujeitas a riscos financeiros, definidos como a possibilidade de ocorrência de perdas decorrentes de investimentos, transações financeiras ou operações de crédito. Tendo em vista isso, fatores como inadimplência, oscilações econômicas e eventos imprevistos, inclusive em âmbito internacional, podem impactar negativamente os resultados financeiros de pessoas e organizações. Nesse contexto, a análise e a gestão de riscos tornam-se atividades essenciais para a tomada de decisões, permitindo a mitigação de perdas e contribuindo para a continuidade e a sustentabilidade das operações (HULL, 2015) .

A crescente digitalização dos serviços financeiros ampliou significativamente o volume de dados disponíveis para análise, ao mesmo tempo em que aumentou a complexidade da gestão de riscos. Diante disso, técnicas de Ciência de Dados e algoritmos de Aprendizado de Máquina passaram a ser amplamente utilizados para prever riscos com maior precisão. Segundo Murugan e T (2023), a análise de grandes volumes de dados financeiros por meio do aprendizado de máquina possibilita a construção de modelos preditivos mais eficazes e alinhados à realidade das instituições.

No contexto do mercado financeiro, a volatilidade dos ativos representa um dos principais desafios para investidores e organizações, uma vez que está diretamente relacionada à incerteza e ao risco. Assim, a previsão da volatilidade de mercado torna-se um elemento fundamental para a tomada de decisões mais seguras e estratégicas, sendo frequentemente utilizada como um indicador relevante de risco financeiro (TANG *et al.,* 2024; CLOUD SECURITY WEB, 2025).

Apesar dos avanços observados na literatura, muitos modelos preditivos ainda enfrentam desafios relacionados não apenas à precisão, mas também à interpretabilidade e à aplicabilidade prática, especialmente em organizações com baixa maturidade tecnológica ou equipes sem formação técnica especializada (TANG *et al.*, 2024; CLOUD SECURITY WEB, 2025). Essa limitação evidencia uma lacuna entre o desenvolvimento de modelos com alto desempenho e sua efetiva utilização no contexto real, restringindo o potencial dessas tecnologias no apoio à tomada de decisão. Dessa forma, torna-se necessário investigar abordagens que conciliam desempenho preditivo, transparência e facilidade de implementação em cenários reais de gestão de riscos financeiros.

Diante desse cenário, este trabalho teve como objetivo desenvolver uma solução baseada em técnicas de Ciência de Dados e Aprendizado de Máquina para a previsão da volatilidade do mercado financeiro, utilizando o Índice Bovespa como indicador representativo do risco de mercado. Para isso, foram empregados modelos preditivos de aprendizado supervisionado, incluindo *XGBoost, LightGBM* e Redes Neurais, aplicados a séries temporais financeiras históricas. O estudo também incorporou técnicas de interpretabilidade, como *SHAP* e *LIME*, visando aumentar a transparência das previsões e seu potencial de aplicação prática. Os resultados obtidos demonstraram que os modelos baseados em *gradient boosting* apresentaram desempenho superior na previsão da volatilidade, com destaque para o *XGBoost*, que alcançou os melhores indicadores de desempenho e capacidade de generalização. Esses resultados evidenciam o potencial das técnicas de Ciência de Dados como ferramentas de apoio à gestão de riscos e à tomada de decisões no mercado financeiro.

2. Desenvolvimento

Esta revisão tem como objetivo apresentar um panorama sistematizado sobre o desenvolvimento da Previsão de Riscos Financeiros com *Data Science* e *Machine Learning*, no período compreendido entre 2016 e 2025. O foco recai sobre as publicações mais recentes e relevantes, contemplando artigos completos em periódicos indexados, livros e trabalhos apresentados em eventos científicos, localizados nas bases Scopus, Web of Science, IEEE Xplore, ScienceDirect e SpringerLink.

Foram adotados como critérios de seleção: (i) publicações dentro do recorte temporal de 2016 a 2025; (ii) relação direta com o tema de previsão de riscos financeiros e aplicação de técnicas de ciência de dados; (iii) clareza metodológica e apresentação de resultados empíricos. O levantamento possibilitou identificar principais tendências, contribuições tecnológicas e desafios éticos associados à aplicação de modelos de *machine learning* em finanças, permitindo compreender como o campo tem evoluído em direção à automatização, precisão preditiva e transparência dos modelos.

2.2 Conceitos Básicos de Risco Financeiro

Os riscos financeiros abrangem uma ampla gama de categorias, como inadimplência, fraudes, risco de crédito, risco operacional e volatilidade de mercado. Dentre esses, a volatilidade de mercado tem recebido destaque na literatura por refletir a magnitude das variações nos preços dos ativos financeiros ao longo do tempo, o que evidencia a instabilidade e a incerteza inerentes ao ambiente econômico global (Nguyen *et al*. 2025; Murugan; T, 2023). Essa instabilidade pode afetar diretamente a capacidade de empresas e investidores em tomar decisões seguras e estratégicas.

Daniel, Brightwood e Oluwaseyi (2024) definem o risco financeiro como a possibilidade de um resultado adverso ou perda resultante de incertezas nos mercados financeiros, nas operações de negócios ou nas condições econômicas, o que reforça sua presença em diversas dimensões das operações financeiras, como concessão de crédito, gestão de investimentos e fluxo de caixa.

Com o avanço da digitalização dos serviços financeiros, Wang *et al.* (2025) destacam que houve um aumento expressivo do volume e da variedade de dados disponíveis, exigindo modelos capazes de considerar as interdependências temporais e as relações complexas entre variáveis financeiras e econômicas.

Autores como Molnar (2020) e Nguyen *et al*. (2025) reforçam que a incapacidade de antecipar adequadamente os riscos pode comprometer não apenas a saúde financeira de empresas, mas também a estabilidade de mercados inteiros. Nesse contexto, Murugan e T (2023) defendem que o risco financeiro deve ser compreendido

como um elemento sistêmico, que demanda monitoramento contínuo e gestão ativa, dada sua capacidade de gerar efeitos em cadeia no sistema econômico global.

2.2.1 Classificação dos Riscos Financeiros

De acordo com Hull (2015), o risco financeiro pode ser classificado nas seguintes categorias:

- Risco de Mercado: envolve oscilações de preços de ativos, variações em taxas de juros, volatilidade e correlação entre instrumentos financeiros.

- Risco de Crédito: relaciona-se à possibilidade de inadimplência de devedores, sejam pessoas físicas, jurídicas ou governos, incluindo exposições a instituições financeiras e derivativos (CVA/DVA).

- Risco de Liquidez: diz respeito à capacidade de converter ativos em dinheiro rapidamente e sem perdas significativas, afetando tanto o mercado quanto as empresas individualmente.

- Risco Operacional: engloba falhas internas em sistemas, erros humanos, fraudes e desastres naturais. Exemplos incluem processamento incorreto de dados e ataques cibernéticos.

- Risco de Modelo: decorre de limitações ou erros nos modelos matemáticos utilizados para avaliação e tomada de decisão.

- Risco Sistêmico e Outros: compreende riscos amplos que afetam todo o sistema financeiro, como risco regulatório, de contraparte e de inovação, frequentemente interdependentes entre instituições.

Essa classificação fornece uma estrutura conceitual que sustenta o desenvolvimento de abordagens analíticas mais precisas e integradas para a previsão e mitigação de riscos no ambiente financeiro contemporâneo.

2.3 Ciência de Dados e *Machine Learning* no Contexto Financeiro

A aplicação de técnicas de ciência de dados e *machine learning* no setor financeiro consolidou-se como uma das principais estratégias para lidar com riscos complexos e ambientes de alta volatilidade. Esse avanço é impulsionado pela necessidade de modelos automatizados, preditivos e adaptáveis, capazes de processar grandes volumes de dados e gerar informações úteis à tomada de decisão (BROWNLEE, 2016).

Essas tecnologias ampliaram a capacidade das instituições financeiras de prever comportamentos futuros, detectar anomalias, calcular risco de crédito e otimizar estratégias operacionais. No entanto, a literatura ainda aponta desafios significativos no equilíbrio entre precisão, interpretabilidade e aplicabilidade prática, especialmente em contextos regulatórios rígidos e com restrições de recursos computacionais.

2.3.1 Fundamentação Conceitual

A base conceitual da ciência de dados no contexto financeiro resulta da integração entre estatística, ciência da computação e conhecimento econômico. Witten *et al.* (2016) descrevem a ciência de dados como uma interseção entre essas áreas, fornecendo os fundamentos teóricos para análises em larga escala. Geron (2019), por sua vez, destaca o papel do *machine learning* como mecanismo de identificação de padrões ocultos e aprendizado a partir de dados históricos, com aplicação prática em ferramentas como *Scikit-Learn* e *TensorFlow*.

Enquanto Witten *et al.* (2016) adotam uma abordagem mais teórica e didática, Geron (2019) enfatiza a implementação prática dos modelos, o que evidencia a lacuna existente entre a formulação conceitual e sua efetiva aplicação em ambientes de produção.

Brownlee (2016) acrescenta que a eficácia dos modelos depende do conhecimento do domínio financeiro, uma vez que algoritmos isolados podem falhar em capturar as nuances dos ciclos econômicos e dos indicadores de mercado. A literatura recente também evidencia o debate entre precisão e interpretabilidade: Tang *et al.* (2024) defendem o uso de modelos mais transparentes, enquanto Geron (2019) e Wang

et al. (2025) exploram o potencial de modelos complexos, como as redes neurais profundas, mesmo que com menor interpretabilidade.

2.3.2 Fundamentação Tecnológica

No campo tecnológico, destacam-se os *frameworks* e bibliotecas computacionais que viabilizam o uso prático dos algoritmos de *machine learning* em finanças. Geron (2019) aponta ferramentas como *Scikit-Learn* e *TensorFlow* como essenciais para o desenvolvimento de modelos clássicos e avançados, desde regressões até redes neurais profundas.

Wang *et al.* (2025) demonstram a aplicação de redes neurais convolucionais (CNNs) em séries temporais financeiras, adaptando-as para reconhecer padrões temporais complexos. Apesar de seu potencial, o próprio autor reconhece que as CNNs apresentam limitações para dados tabulares, formato predominante no setor financeiro, levantando questões sobre custo computacional e transparência dos resultados.

Como alternativa, algoritmos baseados em *boosting*, como *XGBoost* e *LightGBM*, que combinam sequencialmente árvores de decisão simples, em que cada nova árvore corrige os erros residuais das anteriores, gerando uma previsão final a partir da soma ponderada desses modelos fracos tem se mostrado mais adequados para dados financeiros (GERON, 2019). Nguyen *et al.* (2025) , Chang *et al*. (2024) e Suhadolnik *et al*. (2023) comprovam o desempenho superior dessas técnicas em tarefas de previsão de inadimplência e risco de crédito. Além da alta acurácia, esses modelos apresentam vantagens como menor sensibilidade a dados ausentes, menor tempo de treinamento e maior interpretabilidade, fatores essenciais em contextos regulados e sensíveis como o financeiro.

2.4 Desafios e Considerações Éticas na Previsão de Riscos Financeiros

O crescente uso de modelos de aprendizado de máquina na previsão de riscos financeiros trouxe avanços significativos em termos de precisão e capacidade analítica. Sua adoção também levanta desafios relacionados à interpretabilidade, transparência e responsabilidade das decisões automatizadas. Entretanto, esses desafios vão além de

aspectos técnicos: questões éticas e sociais se tornaram fundamentais para garantir que essas tecnologias sejam utilizadas de forma confiável, justa e em conformidade com as outras exigências regulatórias.

2.4.1 Interpretabilidade e Transparência dos Modelos

Mesmo com os avanços observados, persiste uma tensão entre desempenho e interpretabilidade. Molnar (2020) caracteriza modelos complexos, como redes neurais profundas, como “caixas-pretas”, de difícil compreensão e, portanto, menos adequados a ambientes que demandam auditoria e transparência, como o setor financeiro.

Nesse sentido, modelos como o *XGBoost* e o *LightGBM* oferecem equilíbrio entre precisão e interpretabilidade, sendo preferidos por instituições sujeitas a exigências regulatórias mais rigorosas (CHANG *et al.*, 2024).

2.4.2 Impactos Éticos e Sociais

A interpretabilidade assume também um papel ético, uma vez que decisões automatizadas, como aprovação de crédito e definição de limites de financiamento, impactam diretamente indivíduos e organizações. Molnar (2020) ressalta que a transparência dos modelos é condição necessária para a confiança e contestabilidade das decisões algorítmicas, assegurando responsabilidade e controle institucional.

Cloud Security Web (2025) propõe o uso de pipelines automatizados para padronizar etapas como pré-processamento, modelagem e validação, tornando o processo analítico mais transparente e acessível. Brownlee (2016) complementa que a simplicidade e o baixo custo computacional são essenciais para democratizar o uso da inteligência artificial no setor financeiro, evitando a concentração tecnológica em grandes instituições e reduzindo desigualdades digitais.

3. Metodologia

3.1 Tipo de Pesquisa

Com base nos conceitos de Wazlawick (2014), esta pesquisa classifica-se como de natureza aplicada, pois busca utilizar técnicas de Ciência de Dados e Aprendizado de

Máquina para solucionar um problema prático relacionado à gestão de riscos financeiros.

O estudo possui objetivos explicativos, uma vez que procurou compreender e demonstrar como diferentes modelos de *Machine Learning* identificam padrões em séries temporais financeiras e realizam previsões da volatilidade de mercado. Quanto aos procedimentos metodológicos, caracteriza-se como uma pesquisa experimental, pois envolveu a implementação, treinamento, comparação e avaliação de modelos preditivos em ambiente computacional controlado.

Além disso, a pesquisa apresenta abordagem quantitativa, utilizando métricas estatísticas para avaliar o desempenho dos modelos e analisar sua capacidade de previsão do risco de mercado.

3.2 Procedimentos Técnicos de Investigação e Coleta de Dados

Neste estudo, os dados consistiram em séries temporais de ativos financeiros de grande relevância no mercado brasileiro, incluindo Petrobras PN (PETR4), Vale ON (VALE3), Itaú Unibanco PN (ITUB4), Bradesco PN (BBDC4) e Ambev ON (ABEV3). Adicionalmente, foram utilizados o Índice Bovespa (BVSP), representando o comportamento geral do mercado brasileiro, e o índice norte-americano S&P 500 (GSPC), utilizado como indicador complementar de tendências internacionais.

Os dados foram obtidos por meio da biblioteca *YFinance*, que disponibiliza informações históricas provenientes do *Yahoo Finance*. O período analisado compreendeu janeiro de 2016 a março de 2026. O quadro 1 apresenta as principais variáveis utilizadas no estudo.

Quadro 1 - Variáveis Utilizadas na Modelagem

Open	Preço de abertura
High	Preço máximo diário
Low	Preço mínimo diário
Close	Preço de fechamento
Adj Close	Preço de fechamento ajustado

Volume	Volume negociado
Retorno Logarítmico	Variação percentual dos preços
Média Móvel	Tendência de preços
Volatilidade 21 dias	Variável-alvo do estudo

A metodologia adota uma combinação de procedimentos bibliográficos, documentais e experimentais:

- Bibliográfica: envolveu a revisão sistemática da literatura científica recente sobre previsão de riscos financeiros, *Data Science* e *Machine Learning*, com base em publicações das bases *Scopus*, *IEEE Xplore*, *ScienceDirect* e *SpringerLink*, que fundamentam teoricamente o estudo.
- Documental: utilizou dados secundários provenientes do Yahoo Finance, contendo séries históricas de preços, volumes de negociação e indicadores financeiros.
- Experimental: compreendeu a implementação, o treinamento e a avaliação de modelos preditivos em ambiente computacional controlado, utilizando ferramentas de código aberto.

O processo de coleta e preparação dos dados é composto pelas seguintes etapas:

1. Aquisição dos dados históricos por meio da API *Yahoo Finance*;
2. Limpeza e padronização para eliminação de inconsistências e duplicidades;
3. Tratamento de valores ausentes;
4. Normalização e padronização das variáveis para adequação de escalas;
5. Engenharia de atributos, incluindo retornos logarítmicos, médias móveis e volatilidade histórica;
6. Separação temporal dos conjuntos de treino e teste, garantindo previsões realistas e sem vazamento de informações.

A variável-alvo do estudo foi definida como a volatilidade histórica de 21 dias do Índice Bovespa, calculada a partir do desvio-padrão móvel dos retornos logarítmicos, representando uma *proxy* para o risco de mercado.

3.3 Desenvolvimento e Avaliação da Ferramenta Computacional

A ferramenta computacional foi desenvolvida na linguagem *Python*, utilizando bibliotecas amplamente consolidadas na área de Ciência de Dados, incluindo *Pandas* para manipulação e estruturação de dados, *NumPy* para as manipulações matemáticas,

Scikit-Learn para a padronização das variáveis preditoras*, TensorFlow* como contraponto dos modelos de boosting*, XGBoost* e *LightGBM* para a modelagem preditiva*, SHAP e LIME* para verificar a interpretabilidade. O desenvolvimento foi realizado em etapas.

1. Análise Exploratória de Dados (EDA): inicialmente foi realizada uma análise exploratória dos dados, permitindo identificar padrões, correlações e tendências relevantes. Os resultados evidenciaram que os retornos do IBOVESPA apresentam assimetria negativa, elevada curtose e presença de *clusters* de volatilidade, indicando que períodos de volatilidade tendem a ser seguidos por novos períodos de instabilidade, Também foram observadas correlações significativas entre volatilidade futura e variáveis derivadas da volatilidade histórica recente e das médias móveis, confirmando a relevância dessas características para a modelagem preditiva.
2. Treinamento e otimização dos modelos: foram treinados três modelos supervisionados para previsão de volatilidade: *XGBoost, LightGBM* e Rede Neural (MLP). Os modelos passaram por ajustes de hiperparâmetros e seleção de variáveis relevantes. Os resultados demonstram superioridade dos algoritmos baseados em *Gradient Boosting*, especialmente o *XGBoost*, que apresentou o melhor desempenho preditivo e a maior capacidade de generalização quando comparado à rede neural.
3. Validação dos modelos: a avaliação dos modelos foi realizada por meio de validação cruzada temporal utilizando a técnica *TimeSeriesSplit*, apropriada para séries temporais financeiras. Foram utilizadas as métricas *Root Mean Squared Error*(RMSE), *Mean Absolute Error* (MAE) e coeficiente de Determinação(R^2). Os resultados indicaram que o modelo *XGBoost* apresentou o melhor desempenho geral, seguido pelo *LightGBM*. A rede neural apresentou desempenho inferior, possivelmente devido à natureza tabular dos dados e à quantidade limitada de observações disponíveis para treinamento. A validação cruzada temporal demonstrou estabilidade dos modelos ao longo dos diferentes períodos analisados, com RMSE médio de 0,05115 ± 0,07145 para o modelo *XGBoost*.

4. Interpretação dos resultados: com o objetivo de aumentar a transparência das previsões, foram aplicadas as técnicas de *SHAP* (*SHapley Additive exPlanations*) e *LIME (Local Interpretable Model-Agnostic Explanations*). A análise por *SHAP* revelou que a volatilidade histórica de 21 dias foi a variável mais importante para a previsão de volatilidade futura, seguida pelas médias móveis e pelos retornos recentes. Os resultados confirmaram o fenômeno de persistência da volatilidade, amplamente discutido na literatura financeira. As explicações locais produzidas pelo *LIME* mostraram consistência com os resultados obtidos pelo *SHAP*, contribuindo para a compreensão do comportamento dos modelos e aumentando sua confiabilidade para aplicações práticas.
5. Automação do pipeline: foi desenvolvido um pipeline automatizado integrando as etapas de coleta, pré-processamento, engenharia de atributos, treinamento e avaliação dos modelos. Essa automação permitiu a maior reprodutibilidade dos experimentos e redução da complexidade operacional do processo analítico.
6. Visualização dos resultados: os resultados foram apresentados por meio de gráficos, tabelas e métricas de desempenho, permitindo análise clara e acessível. Além disso, foram produzidas visualizações das distribuições dos retornos, comparação entre valores observados e previstos e gráficos de interpretabilidade gerados pelo *SHAP*, permitindo análise clara e acessível do desempenho dos modelos.

3.4 Conexão entre o Método, o Problema e os Objetivos

O método proposto neste estudo estabelece uma conexão direta com o problema de pesquisa, que consiste em melhorar a previsão de riscos financeiros por meio de técnicas de Ciência de Dados e Aprendizado de Máquina. Ao focar na volatilidade de 21 dias como *proxy* para o risco de mercado, a abordagem permite modelar a instabilidade dos preços dos ativos financeiros, um dos principais fatores de risco no contexto financeiro.

A combinação de séries temporais históricas, engenharia de atributos e algoritmos supervisionados possibilitou capturar relações não lineares entre variáveis

financeiras, contribuindo para o desenvolvimento de uma solução preditiva eficiente e aplicável ao contexto da gestão de riscos. Dessa forma, o método adotado mostrou-se adequado para atender ao objetivo da pesquisa, fornecendo previsões consistentes da volatilidade de mercado e informações úteis para o suporte à tomada de decisão.

3.5 Desenvolvimento Metodológico

O desenvolvimento metodológico deste estudo foi estruturado de forma sequencial, contemplando todas as etapas necessárias para a construção e validação da solução proposta. A arquitetura do *pipeline* utilizado neste estudo é apresentada na Figura 1.



Figura 1. Pipeline para Previsões Financeiras Feito com Auxílio da Ferramenta Gemini.

Inicialmente, foi realizada a definição do problema e dos objetivos da pesquisa, delimitando o foco na previsão da volatilidade de mercado como indicador de risco financeiro. Em seguida, procedeu-se à revisão bibliográfica, com o intuito de fundamentar teoricamente o uso de técnicas de Ciência de Dados e *Machine Learning* no contexto financeiro.

Na etapa seguinte, ocorreu a coleta e preparação dos dados, incluindo a obtenção de séries temporais, limpeza, tratamento de valores ausentes, normalização e padronização das variáveis. Posteriormente, foi realizada a análise exploratória dos

dados e a engenharia de atributos, visando identificar padrões relevantes e construir variáveis derivadas que aumentassem o poder preditivo dos modelos.

Em seguida foram treinados e comparados os modelos *XGBoost, LightGBM* e Rede Neural MLP. Após a validação dos resultados, foram aplicadas técnicas de interpretabilidade e desenvolvido um pipeline automatizado para integração das etapas do processo analítico.

Por fim, foram realizadas as análises dos resultados obtidos. Os experimentos demonstraram que os modelos baseados em *Gradient Boosting* apresentaram melhor desempenho na previsão da volatilidade do mercado, com destaque para o *XGBoost*, que alcançou os menores valores de erro e o maior coeficiente de determinação (R^2 = 0,9002). As análises de interpretabilidade indicaram que a volatilidade histórica recente foi a variável mais influente nas previsões, confirmando o comportamento de persistência da volatilidade observado na literatura financeira.

3.6 Limitações

Apesar da robustez metodológica adotada, o presente estudo apresenta algumas limitações. A utilização de dados históricos implica dependência de informações passadas, que podem não refletir completamente eventos futuros ou mudanças estruturais no mercado.

Além disso, o modelo não incorpora variáveis qualitativas, como fatores políticos, decisões regulatórias ou eventos macroeconômicos inesperados, que podem impactar significativamente a volatilidade dos ativos.

Outra limitação refere-se à validação em ambiente controlado, que pode diferir das condições reais de mercado, onde fatores externos e comportamentais exercem influência relevante.

Dessa forma, os resultados devem ser interpretados considerando essas restrições, e melhorias futuras podem ampliar a capacidade preditiva da abordagem proposta.

3.7 Considerações Éticas

Este estudo respeita os princípios éticos da Ciência de Dados, utilizando exclusivamente dados públicos e acessíveis, sem envolver informações sensíveis ou pessoais.

Além disso, buscou-se garantir a transparência dos modelos por meio da aplicação de técnicas de interpretabilidade, permitindo que as decisões automatizadas possam ser compreendidas e auditadas.

A adoção de práticas éticas contribui para a confiabilidade da solução proposta, especialmente em um contexto financeiro, onde decisões baseadas em modelos podem impactar diretamente indivíduos e organizações.

4. Resultados e Discussões

Esta seção apresenta os resultados obtidos a partir da execução do *pipeline* computacional desenvolvido para a previsão da volatilidade do mercado financeiro. O *pipeline* integrou etapas de coleta de dados, pré-processamento, engenharia de atributos, treinamento dos modelos, validação e análise de interpretabilidade, permitindo avaliar a capacidade dos algoritmos em prever a volatilidade do mercado financeiro.

Os dados utilizados foram obtidos por meio da biblioteca *YFinance*, a partir do *Yahoo Finance*, e consistiram em séries temporais diárias dos ativos Petrobras PN (PETR4), Vale ON (VALE3), Itaú Unibanco PN (ITUB4), Bradesco PN (BBDC4), Ambev ON (ABEV3), Índice Bovespa (^BVSP) e S&P 500 (^GSPC). Para cada ativo foram utilizadas as variáveis *Open* (abertura), *High* (máxima), *Low* (mínima), *Close* (fechamento), *Adj Close* (fechamento ajustado) e *Volume*. O período analisado compreendeu janeiro de 2016 a março de 2026, totalizando aproximadamente dez anos de observações diárias do mercado financeiro.

A análise foi conduzida com base nos dados históricos do Índice Bovespa e de ativos representativos do mercado brasileiro, complementados pelo índice S&P 500, utilizado como referência internacional. A volatilidade histórica de 21 dias foi empregada como proxy para o risco de mercado e utilizada como variável-alvo dos modelos preditivos.

Os resultados confirmam que a volatilidade de mercado apresenta comportamento não linear, com presença de eventos extremos e forte dependência temporal, características que justificam o uso de modelos de *Machine Learning* não paramétricos. Estudos recentes, como Silva e Sátiro (2024), também evidenciam o alto desempenho de modelos baseados em *boosting* no contexto do mercado acionário brasileiro, especialmente na previsão de retornos. Diferentemente dessa abordagem, o presente estudo direciona a aplicação desses modelos para a previsão da volatilidade, tratando-a como *proxy* de risco de mercado, o que amplia a análise para além do retorno e contribui para a compreensão do risco financeiro.

4.1 Análise dos Dados e Comportamento do Mercado

A análise exploratória dos dados revelou características estatísticas incompatíveis com os pressupostos de normalidade frequentemente adotados por modelos lineares tradicionais. Os retornos do IBOVESPA apresentaram assimetria negativa, elevada curtose e presença significativa de valores extremos, evidenciados pelos histogramas e gráficos Q-Q Plot.

Esses resultados indicam que a distribuição dos retornos financeiros não segue uma distribuição normal, apresentando maior concentração de observações próximas da média e caudas mais longas, associadas à ocorrência de eventos extremos de mercado. Tais características tornam mais difícil a modelagem por técnicas estatísticas convencionais e reforçam a necessidade da utilização de algoritmos capazes de lidar com padrões complexos.

Observou-se também a presença de *clusters* de volatilidade, nos quais períodos de alta instabilidade tendem a ser seguidos por novos períodos de alta volatilidade. Esse padrão confirma a relevância da utilização de variáveis temporais como preditores e demonstra que a volatilidade passada exerce influência relevante sobre a volatilidade futura.

A não linearidade observada decorre do fato de que a relação entre as variáveis históricas e a volatilidade futura não ocorre de forma proporcional ou constante ao

longo do tempo. Eventos econômicos, crises financeiras, mudanças regulatórias e alterações no comportamento dos investidores produzem padrões complexos, assimétricos e dinâmicos. Dessa maneira, pequenas alterações em determinadas condições de mercado podem resultar em impactos significativamente distintos sobre a volatilidade futura.

Eventos históricos, como a crise política de 2016 e a pandemia de COVID-19 em 2020, impactaram significativamente a série temporal, provocando picos de volatilidade e evidenciando limitações de modelos tradicionais baseados em hipóteses de normalidade.

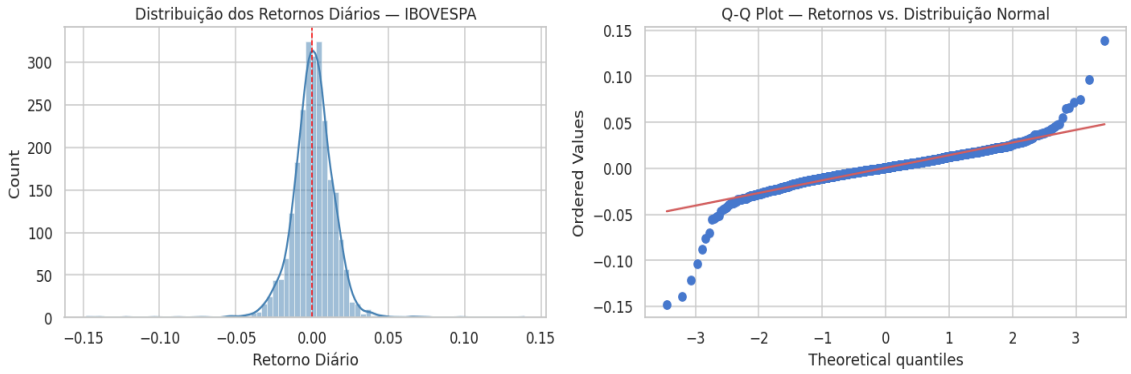


Figura 2 .Distribuição dos Retornos e Q-Q Plot

A Figura 2 demonstra que os retornos do IBOVESPA apresentam desvios significativos da normalidade, evidenciando a presença de assimetria, curtose elevada e eventos extremos. Esses resultados reforçam a adequação da utilização de modelos de *Machine Learning* para a previsão da volatilidade financeira.

4.2 Desempenho dos Modelos Preditivos

Os modelos *XGBoost*, *LightGBM* e Rede Neural MLP foram avaliados com base nas métricas RMSE, MAE e R^2, conforme apresentado na Quadro 2.

Quadro 2 -Comparação dos Modelos Testados

Modelo	RMSE	MAE	R^2
XGBoost	0.01335	0.00959	0.9002

LightGBM	0.01427	0.01049	0.8860
Rede Neural	0.01750	0.01333	0.8286

Os resultados demonstraram que os algoritmos baseados em *Gradient Boosting* apresentaram melhor desempenho na previsão da volatilidade do mercado financeiro. O modelo *XGBoost* obteve os melhores resultados gerais, alcançando RMSE de 0,01335, MAE de 0,00959 e coeficiente de determinação (R^2) de 0,9002. Esse desempenho indica que aproximadamente 90% da variabilidade da volatilidade futura foi explicada pelo modelo, demonstrando elevada capacidade preditiva e boa generalização.

O *LightGBM* apresentou desempenho próximo ao *XGBoos*t, com RMSE de 0,01427, MAE de 0,01049 e R^2 de 0,8860. Embora tenha apresentado erros ligeiramente superiores, os resultados reforçam a robustez desse modelo para aplicações em dados financeiros, especialmente devido à sua eficiência computacional e capacidade de lidar com grandes volumes de dados.

Por sua vez, a Rede Neural MLP apresentou RMSE de 0,01750, MAE de 0,01333 e R^2 de 0,8286, configurando o menor desempenho entre os modelos avaliados. Esse resultado pode estar relacionado à natureza tabular do conjunto de dados utilizados, uma vez que redes neurais tendem a apresentar melhores resultados em cenários com maior volume de observações ou dados não estruturados. Além disso, modelos baseados em árvores de decisão frequentemente demonstram maior eficiência na captura de relações não lineares em bases financeiras estruturadas.

A Figura 3 apresenta a comparação entre os valores reais da volatilidade observada e as previsões geradas pelos modelos. Observa-se que os modelos *XGBoost* e *LightGBM* foram capazes de acompanhar com maior precisão os movimentos de aumento da volatilidade. A Rede Neural, embora tenha capturado a tendencia geral da série, apresentou maior dispersão em relação aos valores observados, especialmente em períodos de maior instabilidade do mercado.



Figura 3. Comparação entre volatilidade real e valores previstos pelos modelos

Os resultados obtidos corroboram estudos recentes da literatura. Silva e Sátiro (2024) verificaram que modelos baseados em *boosting* apresentam elevado poder preditivo no mercado acionário brasileiro, enquanto Chang *et al.* (2024) e Suhadolnik *et al.* (2023) destacam a superioridade do *XGBoost* em problemas de previsão de risco financeiro. Os achados desta pesquisa reforçam essas evidências, demonstrando que técnicas de *Gradient Boosting* são particularmente adequadas para a modelagem da volatilidade de mercado, devido à sua capacidade de capturar relações complexas e não lineares entre variáveis financeiras.

Dessa forma, os resultados indicam que o *XGBoost* representa a alternativa mais eficaz para a previsão da volatilidade do Índice Bovespa no contexto deste estudo, oferecendo elevada precisão preditiva e potencial aplicação em sistemas de suporte à decisão voltados para a gestão de riscos financeiros.

4.3 Validação e Robustez dos Modelos

A validação cruzada temporal confirmou a estabilidade dos modelos em diferentes períodos, com exceção de intervalos que incluem eventos extremos, como a pandemia de 2020. Nesses casos, observou-se aumento significativo do erro, evidenciando a dificuldade inerente à previsão de eventos raros e abruptos.

Ainda assim, o desempenho consistente em períodos de volatilidade moderada indica que os modelos possuem boa capacidade de generalização e são adequados para aplicações práticas em cenários reais.

4.4 Interpretabilidade dos Resultados

A utilização das técnicas *SHAP* e *LIME* para aumentar a transparência das previsões, permitiram compreender o comportamento dos modelos e identificar as variáveis mais relevantes sobre as previsões realizadas pelo modelo *XGBoost.*

A Figura 4 apresenta o gráfico *SHAP Beeswarm*, no qual cada ponto representa uma observação do conjunto de dados. O eixo horizontal indica o impacto da variável na previsão do modelo: valores positivos aumentam a previsão da volatilidade futura, enquanto valores negativos contribuem para sua redução. A cor dos pontos representa a magnitude da variável, variando de azul (valores baixos) a vermelho (valores elevados).

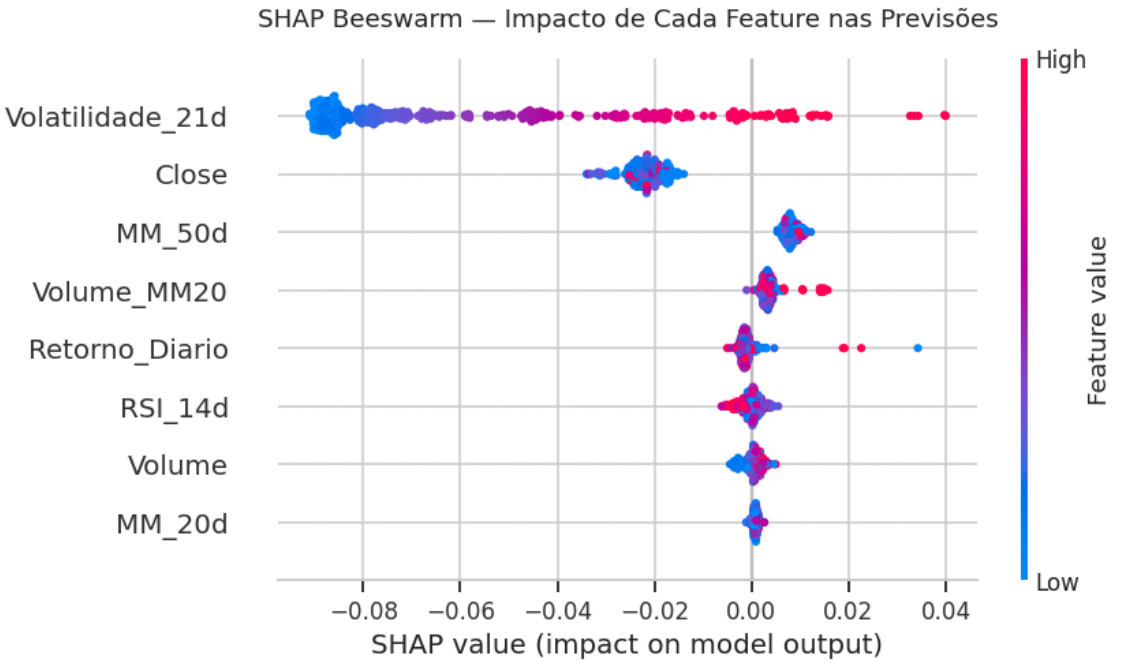


Figura 4 . SHAP Beeswarm: impacto das variáveis na previsão da volatilidade.

A análise *SHAP* permitiu identificar quais variáveis tiveram maior influência nas previsões do modelo. A variável Volatilidade_21d apresentou a maior importância, indicando que períodos recentes de alta volatilidade tendem a aumentar a volatilidade

futura. Esse resultado confirma o fenômeno de persistência da volatilidade, amplamente discutido na literatura financeira.

As variáveis *Close* (preço de fechamento) e MM_50d (média móvel de 50 dias) também exerceram influência relevante, demonstrando que tanto o nível atual dos preços quanto as tendências de médio prazo contribuem para a previsão do risco de mercado.

Além disso, Volume_MM20 (média móvel do volume negociado) e Retorno_Diario apresentaram impacto significativo, sugerindo que períodos de maior atividade de negociação e movimentos mais intensos dos preços estão associados a alterações na volatilidade futura.

As variáveis RSI_14d (Índice de Força Relativa), Volume e MM_20d (média móvel de 20 dias) tiveram menor influência, atuando como fatores complementares para o refinamento das previsões.

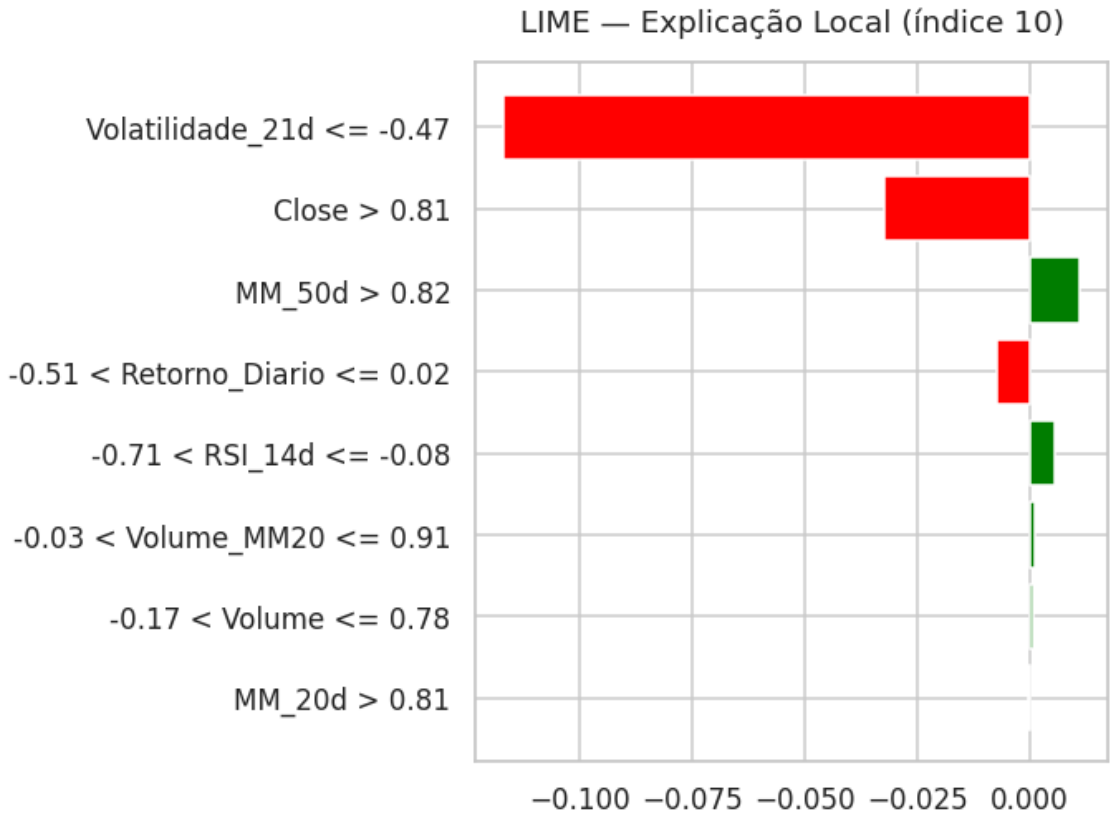


Figura 5. Explicação local das previsões utilizando o método LIME.

A Figura 5 apresenta uma explicação local gerada pelo método *LIME* para uma observação específica do conjunto de testes. Os resultados mostram que a variável Volatilidade_21d exerceu a maior influência na previsão realizada pelo modelo, seguida pelas variáveis Close e MM_50d. As barras em vermelho representam fatores que contribuíram para reduzir a previsão de volatilidade, enquanto as barras em verde indicam fatores que aumentaram a estimativa do modelo. As demais variáveis, como Retorno_Diario, RSI_14d, Volume_MM20, Volume e MM_20d, apresentaram influência menor na decisão analisada. Essa análise permite compreender de forma detalhada os fatores que levaram o modelo a produzir uma previsão específica.

De forma geral, os resultados mostram que o modelo fundamenta suas estimativas principalmente no comportamento histórico da volatilidade e nas tendências do mercado. As explicações obtidas pelo método *LIME* apresentaram resultados consistentes com a análise *SHAP*, reforçando a confiabilidade, a transparência e a interpretabilidade da solução proposta para aplicações em gestão de riscos financeiros

4.5 Implicações Práticas

Os resultados obtidos indicam que a aplicação de técnicas de *Machine Learning* pode contribuir de forma relevante para a previsão de risco de mercado, permitindo que investidores e instituições antecipem períodos de maior instabilidade.

A implementação de um *pipeline* automatizado reduz a complexidade operacional e amplia o acesso a ferramentas analíticas, especialmente para organizações com menor maturidade tecnológica.

5. Conclusão

O presente estudo investigou a aplicação de técnicas de Ciência de Dados e Aprendizado de Máquina na previsão de riscos financeiros, com foco na volatilidade de mercado como indicador de risco. Os resultados demonstraram que modelos baseados em *gradient boosting*, especialmente *o XGBoost*, apresentam elevado desempenho na previsão da volatilidade, evidenciando que abordagens baseadas em dados são eficazes para modelar o risco no mercado financeiro.

Além da precisão, o estudo incorporou técnicas de interpretabilidade, como *SHAP* e *LIME*, contribuindo para a transparência e confiabilidade das previsões, aspecto fundamental em contextos de tomada de decisão. A construção de um *pipeline* automatizado também se mostrou eficiente, tornando a solução proposta viável e acessível.

Como contribuição, o trabalho apresenta uma abordagem prática para previsão de volatilidade, integrando modelagem preditiva e interpretabilidade, além de ampliar o acesso ao uso de técnicas de inteligência artificial no setor financeiro.

Apesar dos resultados positivos, o estudo apresenta limitações relacionadas à dependência de dados históricos e à ausência de variáveis qualitativas, como fatores macroeconômicos e políticos, que podem influenciar o comportamento do mercado.

Como trabalhos futuros, sugere-se a inclusão dessas variáveis, a aplicação de modelos mais avançados, como redes neurais recorrentes e *transformers*, bem como a validação da abordagem em ambientes reais.

Dessa forma, conclui-se que a integração entre técnicas de *Machine Learning*, engenharia de atributos e interpretabilidade representa uma estratégia eficaz para a previsão de riscos financeiros, contribuindo para decisões mais informadas, seguras e estratégicas no mercado.

Referências

ALAGIC, Adnan *et al*. *Machine Learning* for an Enhanced Credit Risk Analysis: A Comparative Study of Loan Approval Prediction Models Integrating Mental Health Data. *Machine Learning* and Knowledge Extraction, [S. l.], v. 6, n. 1, p. 53-77, 2024. DOI: https://doi.org/10.3390/make6010004. Disponível em: https://doi.org/10.3390/make6010004. Acesso em: 20 jan. 2026.

ASSAF NETO, Alexandre. Mercado financeiro. 15. ed. São Paulo: Atlas, 2021.

BROWNLEE, Jason. Machine Learning Mastery With Python: Understand Your Data, Create Accurate Models, and Work Projects End-To-End. Victoria: Machine Learning Mastery, 2016.

CHANG, Victor *et al*. Credit risk prediction using machine learning and deep learning: a study on credit card customers. Risks, [S. l.], v. 12, n. 11, 174, 2024. DOI: https://doi.org/10.3390/risks12110174. Disponível em: https://doi.org/10.3390/risks12110174. Acesso em: 29 jun. 2025.

CLOUD SECURITY WEB. Enhancing Financial Risk Modeling with Machine Learning Pipelines. Cloud Security Web, 28 mar. 2025. Disponível em: https://cloudsecurityweb.com/articles/2025/03/28/enhancing-financial-risk-modeling-with-machine-learning-pipelines/. Acesso em: 29 jun. 2025.

DANIEL, Samon; BRIGHTWOOD, Seraphina; OLUWASEYI, Joseph. Financial big data analytics and risk management. [S. l.: s. n.], 2024. Disponível em: https://www.researchgate.net/publication/385885192_Financial_big_data_analytics_and_risk_management. Acesso em: 10 jun. 2025.

GERON, Aurélien. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems. 2. ed. Sebastopol: O'Reilly Media, 2019.

HULL, John C. Introdução aos derivativos e gestão de riscos. 9. ed. São Paulo: Bookman, 2015.

MOLNAR, Christoph. Interpretable Machine Learning: A Guide for Making Black Box Models Explainable. 2. ed. Munich: Leanpub, 2020. Disponível em: https://christophm.github.io/interpretable-ml-book/. Acesso em: 29 jun. 2025.

MURUGAN, M. Senthil; T, Sree Kala. Large-scale data-driven financial risk management & analysis using machine learning strategies. Measurement: Sensors, [S. l.], v. 27, 100756, 2023. DOI: https://doi.org/10.1016/j.measen.2023.100756.

Disponível em: https://www.sciencedirect.com/science/article/pii/S2665917423000922. Acesso em: 12 jun. 2025.

NGUYEN, Quoc Giang *et al*. Enhancing Credit Risk Management with Machine Learning: A Comparative Study of Predictive Models for Credit Default Prediction. The American Journal of Applied Sciences, [S. l.], v. 7, n. 1, p. 21-30, 2025. DOI: https://doi.org/10.37547/tajas/Volume07Issue01-04. Disponível em: https://www.theamericanjournals.com/index.php/tajas. Acesso em: 8 jun. 2026.

SILVA, José Erasmo; SÁTIRO, Renato Máximo. O poder preditivo dos modelos boosting de machine learning no mercado brasileiro de ações. Contabilometria, [S. l.], v. 11, n. 1, p. 52–68, 2024. Disponível em: https://revistas.fucamp.edu.br/index.php/contabilometria/article/view/2772. Acesso em: 20 jun. 2025.

SUHADOLNIK, Nicolas; UEYAMA, Jo; SILVA, Sergio da. Machine Learning for Enhanced Credit Risk Assessment: An Empirical Approach. Journal of Risk and Financial Management, [S. l.], v. 16, n. 12, 496, 2023. DOI: https://doi.org/10.3390/jrfm16120496. Disponível em: https://doi.org/10.3390/jrfm16120496. Acesso em: 8 jun. 2025.

TANG, Pan; TANG, Tiantian; LU, Chennuo. Predicting systemic financial risk with interpretable machine learning. The North American Journal of Economics and Finance, [S. l.], v. 71, 102088, 2024. DOI: https://doi.org/10.1016/j.najef.2024.102088. Disponível em: https://www.sciencedirect.com/science/article/abs/pii/S1062940824000123. Acesso em: 9 ago. 2025.

WANG, Zhen. Application of CNN-based financial risk identification and management convolutional neural networks in financial risk. Systems and Soft Computing, [S. l.], v. 7, 200215, 2025. DOI: https://doi.org/10.1016/j.sasc.2025.200215. Disponível em: https://doi.org/10.1016/j.sasc.2025.200215. Acesso em: 8 jun. 2025.

WITTEN, Ian H.; FRANK, Eibe; HALL, Mark A.; PAL, Christopher J. Data Mining: Practical Machine Learning Tools and Techniques. 4. ed. Burlington: Morgan Kaufmann, 2016.